

DOI: 10.13228/j.boyuan.issn1006-9356.20180318

基于孪生支持向量回归机的转炉炼钢终点预测

高 闯¹, 沈明钢¹, 王焕清²

(1. 辽宁科技大学材料与冶金学院, 辽宁 鞍山 114051; 2. 辽宁科技大学电子与信息工程学院, 辽宁 鞍山 114051)

摘 要: 为了提高转炉炼钢的终点命中率, 建立了一种新的转炉终点预测模型, 实现了对转炉终点碳质量分数和温度的准确预测。模型采用 K 最近邻孪生支持向量机(KNNWTSVR)算法, 将权重矩阵引入到目标函数中, 并利用鲸群优化算法进行求解, 提高了传统算法的性能; 然后基于某炼钢厂 260 t 转炉的实际生产数据, 建立了转炉炼钢终点预测模型。结果表明, 预测模型的终点碳质量分数(误差 $\pm 0.005\%$)和温度(误差 $\pm 15\text{ }^{\circ}\text{C}$)的终点单命中率分别为 94% 和 88%, 双命中率达到 84%。与其他两种现有的建模方法相比, 本模型取得了最优的预测效果。该方法满足转炉炼钢实际生产的需求, 也可适用于钢铁冶金其他领域的数学建模。

关键词: 转炉炼钢; 终点预测模型; 孪生支持向量回归机; 鲸群优化算法

文献标志码: A **文章编号:** 1006-9356(2019)04-0012-05

End-point prediction of BOF steelmaking based on twin support vector regression

GAO Chuang¹, SHEN Ming-gang¹, WANG Huan-qing²

(1. School of Materials and Metallurgy, University of Science and Technology Liaoning, Anshan 114051, Liaoning, China; 2. School of Electronic and Information Engineering, University of Science and Technology Liaoning, Anshan 114051, Liaoning, China)

Abstract: In order to improve the end-point hit rate of basic oxygen furnace (BOF) steelmaking, a new prediction model of BOF end-point is established to achieve the accurate prediction of the carbon content and temperature at the end of the converter. K-nearest neighbor weighted based twin support vector regression (KNNWTSVR) is adopted for the model. A KNN weighted matrix is introduced to the objective functions, and the whale optimization algorithm is used to solve the objective functions to improve the performance of the algorithm. Then, based on the data-sets of a 260 t BOF, the prediction model for converter steelmaking end-point is established. The experimental results show that the predicted hit rates of the end-point carbon content (error $\pm 0.005\%$) and temperature (error $\pm 15\text{ }^{\circ}\text{C}$) are 94% and 88%, respectively, and the double hit rate achieves 84%. Compared with the other two existing modeling methods, the proposed model obtains the best prediction effect. Therefore, it meets the requirements of the real production of converter steelmaking, and it is also suitable for mathematical modeling in other fields of metallurgy.

Key words: BOF steelmaking; end-point prediction model; twin support vector regression; whale optimization algorithm

近年来,智能算法在钢铁冶金领域的应用已经取得很多成果,由于神经网络具有很强的非线性逼近能力,因此,很多学者利用神经网络建立了炼铁过程的预测模型^[1-4]以及转炉炼钢的终点预测和控制模型^[5-7]。高精度的转炉炼钢预测模型起着非常重要的作用,它不仅是建立控制模型的前提,也能够为控制模型的精度提供有力保障。从目前已取得的成果看,大部分转炉预测模型采用神经网络。基于神

经网络的模型的主要问题是建模求解过程中容易陷入局部最小,导致模型的精度不高,传统的支持向量回归机虽然很好地解决了局部最小值的问题,但是在运算效率方面存在缺陷。因此,2007年,文献[8]提出了孪生支持向量机(TSVM)算法,该方法与传统的支持向量回归机相比,大幅减少了求解优化问题的运算量,适用于分类问题的研究。2010年,在TSVM基础上,文献[9]提出了孪生支持向量回归

基金项目: 国家自然科学基金资助项目(61773072)

作者简介: 高 闯(1982—),男,博士,讲师; E-mail: 13500422153@163.com; 收稿日期: 2018-10-16

通讯作者: 沈明钢(1958—),男,博士,教授; E-mail: lnassmg@163.com

机(TSVR)算法,该方法能够利用实际的工业数据建立系统的预测模型。此后,相关文献[10-11]对TSVR算法进行了推广和改进,提高了算法精度。所以,本文采用文献[10]中的KNNWTSVR算法,建立了基于副枪技术的转炉炼钢接近吹炼终点阶段的预测模型。在冶炼后期,熔池内部的物理化学反应趋于稳定,在此阶段预测熔池的终点碳质量分数和温度,模型能够达到更高的精度。本文所提出的模型为转炉炼钢建模领域的研究提供了一个新的思路,同时,与传统的建模方法相比,本模型具有较高的终点命中率,能够满足实际现场生产的需求。

1 转炉炼钢的终点预测模型

在转炉炼钢的实际生产过程中,预测模型具有重要的指导意义,因为钢水的终点碳质量分数和终点温度是衡量炼钢质量的主要因素,炼钢的最终目的是控制终点碳质量分数和温度达到规定区域。终点预测模型是终点控制模型的基础,所以有必要建立准确的预测模型。从转炉终点预测模型研究的相关文献可以看出,基于智能方法的数学模型研究是转炉炼钢终点预测的发展趋势,神经网络是建立转炉预测模型的主要方法,但是采用神经网络建模的最大弊端是局部最小值问题,导致模型参数不唯一,使得建模难度增大,而且如果样本数量过少,建模效果难以保证。相比之下,孪生支持向量机通过求解二次规划问题获得回归模型。由于二次规划问题是一个凸问题,该问题必然存在全局最优解,避免了局部最小值的问题。同时,该方法相比传统算法在运算效率上也得到了很大的提升,因此,利用TSVR算法和转炉的历史数据,通过机理分析,确定影响转炉终点信息的影响因素,建立转炉炼钢终点预测模型。尽管TSVR解决了传统方法中存在的问题,但是其目标函数中并未考虑各个样本之间的权重问题,针对这个问题,采用K最近邻权重TSVR算法建立基于副枪的转炉补吹阶段的终点预测模型。

2 非线性KNNWTSVR算法

非线性TSVR算法利用复杂未知的非线性系统的已知样本,建立该系统的回归模型并用于预测。传统的支持向量回归机算法通过求解一个大的二次规划问题,最终得到回归函数;而TSVR算法则是求解两个小的二次规划问题得到两个回归函数,最终的回归函数由这两个函数加权平均得到,从而实

现运算量的简化。假设样本是一个 n 维向量,样本数量为 l ,其可表示为 $(x_1, y_1), \dots, (x_l, y_l)$ 。令矩阵 $A = [x_1, \dots, x_l]^T \in R^{l \times n}$ 为输入样本,向量 $y = [y_1, \dots, y_l]^T \in R^l$ 为输出样本,向量 $e = [1, \dots, 1]^T$ 为适当维度的单位向量。如果 $K(\cdot)$ 为一个非线性核函数,则令 $K(A, A^T)$ 为一个 l 维核矩阵,其中第 (i, j) 个元素 $(i, j = 1, 2, \dots, l)$ 定义为^[9]

$$[K(A, A^T)]_{i,j} = K(x_i, x_j) = (\Psi(x_i) \cdot \Psi(x_j)) \in R \quad (1)$$

式中: $K(x_i, x_j)$ 为高维特征空间中的非线性映射函数 $\Psi(x_i)$ 和 $\Psi(x_j)$ 的内积。

有多种核函数可供选择,本文选取的是高斯核函数^[9-11],其表达式为

$$K(x, x_i) = \exp\left(-\frac{\|x - x_i\|^2}{2\sigma^2}\right) \quad (2)$$

式中: σ 为核函数的宽度。

令 $K(x^T, A^T) = (K(x, x_1), K(x, x_2), \dots, K(x, x_l))$ 为一个 l 维行向量,则两个回归函数的表达式可表示为 $f_1(x) = K(x^T, A^T)\omega_1 + b_1$ 和 $f_2(x) = K(x^T, A^T)\omega_2 + b_2$,其中 $\omega_1, \omega_2 \in R^l$ 为法向量, $b_1, b_2 \in R$ 为偏置。因此,最终的回归函数可表示为

$$f(x) = f_1(x) + f_2(x) \quad (3)$$

2014年,XU Y等^[10]提出了一种基于K最近邻权重的TSVR算法。每个训练数据的权重由它的最接近的 K 个邻居来决定,KNN权重矩阵可以定义为

$$\omega_{i,j} = \begin{cases} 1, & x_i \text{ 是 } x_j \text{ 的 } K \text{ 最近邻或 } x_j \\ & \text{是 } x_i \text{ 的 } K \text{ 最近邻} \\ 0, & \text{其他} \end{cases} \quad (4)$$

为了体现每个采样点的重要性,定义一个新的变量 $d_i = \sum_{j=1}^l \omega_{i,j}$, $i = 1, 2, \dots, l$ 。较大的 d_i 反映出该样本点拥有更多的邻居,邻居数量的大小影响该点在整个样本中的重要程度。通过引入上述权重矩阵,非线性KNNWTSVR的目标函数可由目标函数(式(5)和式(6))表示。

$$\begin{aligned} \min_{\omega_1, b_1, \xi} & \frac{1}{2} [y - (K(A, A^T)\omega_1 + b_1 e)]^T \\ & D[y - (K(A, A^T)\omega_1 + b_1 e)] + c_1 e^T \xi \\ \text{s. t. : } & y - (K(A, A^T)\omega_1 + b_1 e) \geq \\ & -\varepsilon_1 e - \xi, \xi \geq 0e, \end{aligned} \quad (5)$$

$$\begin{aligned} \min_{\omega_2, b_2, \gamma} & \frac{1}{2} [y - (K(A, A^T)\omega_2 + b_2 e)]^T \\ & D[y - (K(A, A^T)\omega_2 + b_2 e)] + c_2 e^T \gamma \\ \text{s. t. : } & K(A, A^T)\omega_2 + b_2 e - y \geq \end{aligned}$$

$$-\varepsilon_2 e - \gamma, \gamma \geq 0e \quad (6)$$

式中: $c_1, c_2, \varepsilon_1, \varepsilon_2$ 为调整参数, 均不小于 0; 矩阵 $D = \text{diag}(d_1, d_2, \dots, d_l)$ 。

与传统的 TSVR 的求解方法类似, 得到式(5)和式(6)的对偶问题, 见式(7)和式(8)。

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \alpha^T H (H^T D H)^{-1} H^T \alpha + y^T \alpha + \\ & \varepsilon_1 e^T \alpha - y^T D H (H^T D H)^{-1} H^T \alpha \\ \text{s. t. :} \quad & 0e \leq \alpha \leq c_1 e \end{aligned} \quad (7)$$

$$\begin{aligned} \min_{\beta} \quad & \frac{1}{2} \beta^T H (H^T D H)^{-1} H^T \beta + \varepsilon_2 e^T \beta - \\ & y^T \beta - y^T D H (H^T D H)^{-1} H^T \beta \\ \text{s. t. :} \quad & 0e \leq \beta \leq c_2 e \end{aligned} \quad (8)$$

式中: $H = [A \ e]$ 。

值得注意的是, 上述对偶问题需要对 $H^T D H$ 矩阵求逆, 为了避免病态矩阵的问题, 通过引入正则化项 ρI (ρ 为一个非常小的正数), 并求解上述优化问题, 通过式(9)和式(10)计算出 ω_1, b_1 和 ω_2, b_2 , 最后将结果代入式(3)可得到回归函数 $f(x)$ 。

$$\begin{bmatrix} \omega_1 \\ b_1 \end{bmatrix} = (H^T D H + \rho I)^{-1} H^T (D y - \alpha) \quad (9)$$

$$\begin{bmatrix} \omega_2 \\ b_2 \end{bmatrix} = (H^T D H + \rho I)^{-1} H^T (D y + \beta) \quad (10)$$

3 转炉终点预测模型的建模过程

3.1 模型描述

转炉炼钢是一个复杂的物理化学过程, 其数学模型很难建立, 因此, 可利用 TSVR 算法逼近转炉终点预测模型。由于副枪测定后的转炉内部的物理化学反应趋于稳定, 因此, 在此阶段建立转炉的预测模型可以达到更高的精度。通过机理分析, 找到影响转炉终点信息的因素, 即将这些影响因素作为预测模型的输入变量。相关的输入变量见表 1。值得注意的是, 碳含量预测模型和温度预测模型的输入变量的数目是不同的。由于在吹炼后期, 冷却剂只影响终点温度, 也就是说碳含量预测模型只有 3 个输入变量, 而温度预测模型有 4 个输入变量。预测模型的输出变量是终点碳含量或终点温度。

3.2 建模参数的选取和建模步骤

本文采集的样本来自某炼钢厂 260 t 转炉实际生产数据, 样本数量为 250 组。前 200 组样本作为训练样本, 后 50 组作为测试样本。因为 KNNWTSVR 算法所逼近的系统为多输入单输出系统, 因此, 需要分别建立终点碳含量和终点温度两个

预测模型。

表 1 碳含量和温度预测模型的输入
Table 1 Inputs for carbon content and temperature prediction model

模型	输入变量	符号
碳含量预测模型	副枪碳质量分数	$x_1/\%$
	副枪温度	$x_2/^\circ\text{C}$
	补吹氧气量	x_3/m^3
温度预测模型	副枪碳质量分数	$x_1/\%$
	副枪温度	$x_2/^\circ\text{C}$
	补吹氧气量	x_3/m^3
	冷却剂量	x_4/t

参数的选取可以采取逐一调整的方式, 即固定其他参数, 只调整一个参数, 每次调整都对 200 组样本进行训练, 然后对 50 组样本进行测试, 根据预测输出和实际输出的误差, 计算出模型的精度, 直到调整到当前参数下的模型精度最高停止, 保存此参数数值, 然后进行下个参数的调整, 直到完成所有参数的调整。

利用预测模型的参数, 通过求解 KNNWTSVR 的目标函数的对偶问题可以确定转炉的预测模型。2016 年, 格里菲斯大学的 Mirjalili S 等^[12]提出了鲸群优化算法 (whale optimization algorithm, 简称 WOA), 它通过模仿鲸鱼狩猎捕食的行为进而提出一种新的优化算法, 与其他优化算法相比, 其优势在于调节参数简单, 运算速度较快。因此, 本文采用鲸群优化算法求解 KNNWTSVR 的优化问题。鲸群优化采用策略见式(11)。鲸群优化算法根据上述 3 条策略反复迭代, 最终求得最优解。

$$\begin{aligned} X(t+1) = & \\ \begin{cases} X^*(t) - \tau P, & \text{if } a < 1, \\ X_{\text{rand}} - \tau P, & \text{if } a \geq 1, \\ X^*(t) + \tau_p e^{\varepsilon \cdot v} \cdot \cos(2\pi v), & \text{if } p \geq 0.5 \end{cases} & \text{if } p < 0.5 \end{aligned} \quad (11)$$

式中: t 为当前迭代数; τ 为常数, 表示更新距离的大小; P 为系数向量; $X^*(t)$ 为当前最优解的位置向量; $X(t)$ 为当前座头鲸的位置向量; X_{rand} 为座头鲸的随机位置向量; τ_p 为鲸鱼和猎物之间的距离; a 为从 2 下降到 0 的变量; ε 为常数, 用于描述螺旋运动的形状; v 为在 $[-1, 1]$ 区间内的随机向量; p 为概率变量。

转炉终点预测模型的建模步骤如下: 第 1 步, 读取终点碳含量数据或终点温度数据, 利用 K 最近邻算法对数据进行预处理; 第 2 步, 确定 K 最近邻权重矩阵 D ; 第 3 步, 初始化鲸群优化的种群数量; 第

4步,初始化模型参数,将200组训练样本代入式(7)和式(8)中,根据式(11)的优化策略,求解该优化问题,直到满足最大迭代次数,得到最优解向量 α 或 β ;第5步,将最优向量代入式(9)和式(10),求出 ω_1, b_1 和 ω_2, b_2 ;第6步,将结果代入式(3),得到终点碳含量预测模型 $f_C(x)$ 或终点温度预测模型 $f_T(x)$;第7步,将50组测试样本代入预测模型,得到终点碳含量或终点温度的预测值。计算模型精度和终点命中率等指标,如果指标达到设定值,模型建立完成,否则重复第3步到第7步,直到指标达到设定值。

4 试验结果和分析

本次试验采用的软件为MATLAB R2011b。在建立转炉的数学模型后,需要一些相关的指标来评价这个模型的好坏。模型的性能指标通常利用预测结果和实际结果的一些数学运算得到,对于转炉炼钢的终点预测模型,假设测试样本的数量为 n ,测试样本的实际输出为 y_i ,所有输出的平均值为 \bar{y}_i ,模型的预测值为 \hat{y}_i ,则可采用以下性能指标进行分析和评判:(1) $RMSE$:表示均方根误差^[13],是预测值与实际值误差的平方与测试样本数量 n 比值的平方根,可以准确反映转炉模型预测误差的大小,其表达式为 $RMSE = \sqrt{\sum_{i=1}^n (y_i - \hat{y}_i)^2 / n}$ 。(2) MAE :表示平均绝对误差^[13],是预测值与实际值误差的绝对值的平均,也是反映模型预测误差大小的一个指标,其表达式为 $MAE = \sum_{i=1}^n |y_i - \hat{y}_i| / n$ 。(3) SSE/SST :表征测试数据和训练模型的拟合程度^[9], SSE/SST 越小,说明测试数据与训练模型的拟合程度越好,其表达式为 $SSE/SST = \sum_{i=1}^n (y_i - \hat{y}_i)^2 / \sum_{i=1}^n (y_i - \bar{y}_i)^2$ 。值得注意的是,如果 SSE/SST 非常小,则会出现过拟合现象,即模型已经失去了对测试数据的预测能力。(4) SSR/SST :反映的是所有预测值的波动与实际值波动的同步程度^[9],数值等于1说明两者的波动程度一致,数值太小或太大都会导致模型失去预测能力,其数学表达式为 $SSR/SST = \sum_{i=1}^n (\hat{y}_i - \bar{y}_i)^2 / \sum_{i=1}^n (y_i - \bar{y}_i)^2$ 。(5) HR :表示在特定误差范围内的终点碳含量或终点温度的命中率,其数学表达式为 $HR = (|y_i - \hat{y}_i| \leq n_e) / n \times 100\%$, n_e 为设定误差的样本数量。双命中率 DHR 也是评价转炉炼钢好坏的一个重要指标,即碳含量和温度同时命中的样本数量

占全部样本数量的比例。

为了验证模型的效果,选取第3.2节提到的250组260 t转炉数据进行建模。试验结果与现有的两种典型的TSVR回归方法进行比较,3种TSVR回归方法的性能对比见表2。在转炉炼钢的实际应用中,如果目标碳质量分数为0.04%,目标温度为1 680℃,则0.005%的终点碳质量分数和15℃的终点温度预测误差能够满足现场的要求。因此,上述两个阈值分别为碳含量和温度预测模型的误差容限。

表2 3种TSVR回归方法的性能对比

模型	指标	KNNWTSVR	TSVR	v-TSVR
碳含量模型	$RMSE$	0.002 1	0.003 2	0.003 0
	MAE	0.002 3	0.002 4	0.002 5
	SSE/SST	0.420 3	0.336 3	0.302 6
	SSR/SST	0.892 3	0.941 8	1.226 7
	$HR/\%$	94	88	92
温度模型	$RMSE$	8.110 6	13.292 0	9.376 9
	MAE	8.662 1	10.188 6	7.482 1
	SSE/SST	0.551 0	0.802 7	0.399 5
	SSR/SST	0.821 1	1.080 0	0.809 3
	$HR/\%$	88	82	89
	$DHR/\%$	84	74	82

试验结果表明,所提出的碳含量模型的预测效果如图1所示,其 $RMSE$ 和 MAE 分别达到0.002 1和0.002 3,说明测试样本中碳含量的预测值与实际值的平均误差在0.002%左右,低于设定的0.005%的误差容限,且这两项指标均小于其他两种回归方法;从 SSE/SST 和 SSR/SST 的结果可以看出,所提出的碳含量模型的 SSE/SST 达到0.420 3, SSR/SST 达到0.892 3,这两个指标均略低于其他两种方法,但是碳含量命中率达到94%,高于其他两种方法的88%和92%。因此,从总体上看,所提出的碳含量模型的预测效果优于其他两种模型的预测效果。

所提出的温度模型的预测效果如图2所示,其 $RMSE$ 和 MAE 的结果在3种方法中最小,分别达到8.110 6和8.662 1,说明本模型的温度预测的平均误差在8.5℃左右,满足预先设定的15℃的误差容限。 SSE/SST 和 SSR/SST 在3种方法中排名第2。在温度的终点命中率方面,所提出的温度模型的命中率可以达到88%,虽然v-TSVR模型的单命中率达到89%,但是它的碳含量单命中率和双命中率低于本文提出的模型。因此,所提出的模型

取得了最优的预测效果,双命中率达到 84%,基本符合现场的需求。




图 1 提出的碳含量预测模型的预测结果

Fig. 1 Performance of proposed carbon content model




图 2 提出的温度预测模型的预测结果

Fig. 2 Performance of proposed temperature model

综上所述,可以看出,通过 K 最近邻权重,在 TSVR 的目标函数中给予每个样本的预测误差不同的权重,能够有效地提高算法性能。所提出的转炉炼钢终点预测模型的建模方案是行之有效的,终点碳含量和终点温度的单命中率达到了预期的效果,双命中率的结果符合静态预测模型的要求,适用于转炉炼钢的实际背景,可为后续研究静态控制和动态控制模型提供理论依据。

5 结论

(1)首次采用孪生支持向量建立转炉炼钢的终

点预测模型,算法性能优于基于神经网络的转炉终点预测模型。

(2)利用基于 KNN 权重的孪生支持向量机算法,提高了传统算法的泛化性能,使得转炉终点碳含量和终点温度的预测精度进一步提升。

(3)采用 MATLAB 软件,结合实际的转炉生产数据,所提出的碳含量模型和温度模型的终点命中率分别可达 94%和 88%,双命中率达到 84%,取得了较优的预测效果,且符合实际现场的需求。因此,该方法对转炉炼钢的实际生产有一定的指导意义。

(4)在该模型的基础上,可进一步建立转炉炼钢的终点控制模型,通过控制吹氧量和冷却剂加入量,确保钢水的成分和温度达到终点预测。

参考文献:

- [1] 高绪东. BP 神经网络在高炉铁水硅预报中的应用[J]. 中国冶金, 2014, 24(6): 24.
- [2] 崔桂梅, 李静, 张勇, 等. 基于 T-S 模糊神经网络模型的高炉铁水温度预测建模[J]. 钢铁, 2013, 48(11): 11.
- [3] 任彦军, 王家伟, 张晓兵, 等. 基于 LM 算法 BP 神经网络的高炉-转炉界面铁水温度预报模型[J]. 钢铁, 2012, 47(9): 40.
- [4] 赵路朋, 吴铿, 朱利, 等. 基于 BP 神经网络的烧结矿性能预报模型[J]. 钢铁, 2017, 52(9): 11.
- [5] 丁容, 刘浏. 转炉炼钢过程人工智能静态控制模型[J]. 钢铁, 1997, 32(1): 22.
- [6] 李小环. 转炉终点残锰量控制及优化[J]. 中国冶金, 2016, 26(5): 57.
- [7] Frattini Fileti A M, Pacianotto T A, Pitasse Cunha A. Neural modeling helps the BOS process to achieve aimed end-point conditions in liquid steel[J]. Eng Appl Artif Intell, 2006, 19(1): 9.
- [8] Jayadeva, Khemchandani R, Chandra S. Twin support vector machines for pattern classification[J]. IEEE Trans Pattern Anal Machine Intell, 2007, 29(5): 905.
- [9] PENG X. TSVM: An efficient twin support vector machine for regression[J]. Neural Netw, 2010, 23(3): 365.
- [10] XU Y, WANG L. K-nearest neighbor-based weighted twin support vector regression[J]. Appl Intell, 2014, 41(1): 299.
- [11] XU Y, LI X, PAN X, et al. Asymmetric ν -twin support vector regression[J]. Neural Comp Appl, 2017(2): 1.
- [12] Mirjalili S, Lewis A. The whale optimization algorithm[J]. Advances in Engineering Software, 2016, 95: 51.
- [13] 贾俊平, 何晓群, 金勇. 统计学[M]. 4 版. 北京: 中国人民大学出版社, 2009.